# Proyecto Final: Modelos Estadísticos

*Análisis estadístico de la base de datos* `Wine.csv`

**Alexis Alberto Zúñiga Alonso**
**Baruc Azael Ramírez Romo**

Profesor: Axel Torres
*EdgeHub | School of Innovation*
9 de octubre de 2026

## Descripción

La base de datos `Wine.csv` contiene 178 muestras de vino y 14 variables. Trece de ellas son mediciones químicas de cada muestra y la variable `Customer_Segment` se interpreta como el **pueblo** donde se extrajo el vino (1, 2 o 3). La variable `Proline` se define como la concentración de prolina en mg/L.

El trabajo sigue los tres apartados del script de R: (1) limpieza de datos, (2) análisis exploratorio y (3) inferencia estadística y modelos. Cada fragmento de código se acompaña de una descripción del procedimiento y de los resultados numéricos que produjo.

## 0. Preparación del entorno

```
# Instala (si faltan) y carga los paquetes; MASS y nnet se llaman con `::` para no enmascarar dplyr::select
libs <- c("tidyverse", "car", "rstatix", "ggpubr", "caret", "patchwork")
faltantes <- libs[!libs %in% rownames(installed.packages())]
if (length(faltantes) > 0) install.packages(c(faltantes, "MASS", "nnet"))
invisible(lapply(libs, library, character.only = TRUE))
```

Se cargan los paquetes utilizados: `tidyverse` (manipulación de datos y gráficas), `car` (prueba de Levene, VIF y Breusch-Pagan), `rstatix` (pruebas de hipótesis y tamaños de efecto), `ggpubr` y `patchwork` (anotación y composición de gráficas), `caret` (partición de datos, validación cruzada y métricas), `MASS` (selección de variables por AIC) y `nnet` (regresión logística multinomial). El análisis se ejecutó en R 4.6.1.

## 1. Limpieza de datos

### 1.a Comprensión de las variables y sus registros

```
# Carga de datos crudos y vistazo a la estructura (178 muestras x 14 variables)
wine_raw <- read_csv("data/Wine.csv", show_col_types = FALSE)
glimpse(wine_raw)
```

Se leen los datos crudos y `glimpse()` muestra su estructura: 178 filas, 14 columnas, todas leídas por R como numéricas. Con base en ello se construyó un diccionario de datos con la descripción, unidad propuesta y tipo estadístico de cada variable (Tabla 1).

**Tabla 1.** Diccionario de datos.

| Variable | Descripción | Unidad |
|---|---|---|
| `Alcohol` | Contenido de alcohol | % vol |
| `Malic_Acid` | Ácido málico | g/L |
| `Ash` | Cenizas (residuo mineral) | g/L |
| `Ash_Alcanity` | Alcalinidad de las cenizas | meq/L |
| `Magnesium`[d] | Magnesio | mg/L |
| `Total_Phenols` | Fenoles totales | g/L |
| `Flavanoids` | Flavonoides | g/L |
| `Nonflavanoid_Phenols` | Fenoles no flavonoides | g/L |
| `Proanthocyanins` | Proantocianidinas (taninos) | g/L |
| `Color_Intensity` | Intensidad de color | absorb. |
| `Hue` | Tonalidad del color | razón |
| `OD280` | Razón OD280/OD315 | razón |
| `Proline`[d] | Concentración de prolina | mg/L |
| `Customer_Segment`[n] | Pueblo de origen (1, 2, 3) | — |

Todas son cuantitativas continuas, salvo [d]cuantitativa discreta y [n]cualitativa nominal.

```
# Clase con la que R leyó cada variable y número de valores distintos (Customer_Segment solo tiene 3)
tibble(Variable = names(wine_raw),
       Clase_R  = map_chr(wine_raw, class),
       Valores_distintos = map_int(wine_raw, n_distinct))

# Número de muestras por pueblo (clases moderadamente desbalanceadas: 59, 71 y 48)
count(wine_raw, Customer_Segment)
```

Contar los valores distintos permite distinguir el tipo de variable: `Customer_Segment` solo toma 3 valores, por lo que es *cualitativa nominal* aunque R la lea como número; el resto toma entre 39 y 133 valores distintos. El conteo por pueblo da 59, 71 y 48 muestras (Figura 1).

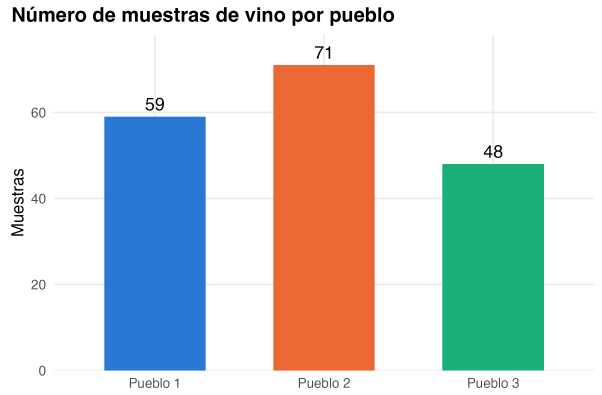



**Figura 1.** Número de muestras de vino en cada pueblo: 59 en el Pueblo 1, 71 en el Pueblo 2 y 48 en el Pueblo 3.

### 1.b Enfoque del análisis

El enfoque es **mixto**: *exploratorio* en la sección 2, para describir las variables, e *inferencial y predictivo* en la sección 3, para comparar los pueblos, modelar la prolina y clasificar el pueblo de origen.

### 1.c Detección de NAs, duplicados y valores anómalos

```
# Conteo de NAs por variable
colSums(is.na(wine_raw))

# Filas completamente duplicadas
sum(duplicated(wine_raw))

# Valores negativos (imposibles en concentraciones químicas)
colSums(wine_raw < 0, na.rm = TRUE)

# Valores con más de 3 decimales: artefactos de formato (p. ej. Color_Intensity = 9.899999)
wine_raw %>%
  mutate(fila = row_number()) %>%
  pivot_longer(-fila, names_to = "Variable", values_to = "Valor") %>%
  filter(abs(Valor * 1000 - round(Valor * 1000)) > 1e-6)
```

Se revisan cuatro problemas posibles. Resultados: **0** valores faltantes (NA) en todas las variables, **0** filas duplicadas y **0** valores negativos. Se encontró **1** valor con más de tres decimales (fila 172, `Color_Intensity` = 9.899999), atribuible a un error de formato.

### 1.d Tratamiento de los casos detectados

```
# Pipeline de limpieza: aplica cada paso solo si el problema existe, así sirve para futuras versiones del CSV
wine <- wine_raw %>%
  mutate(across(everything(), ~ round(.x, 3))) %>%  # elimina artefactos de redondeo
  filter(!is.na(Customer_Segment)) %>%  # sin pueblo no se puede imputar
  mutate(Pueblo = factor(Customer_Segment, levels = 1:3, labels = names(colores_pueblo))) %>%
  select(-Customer_Segment) %>%
  group_by(Pueblo) %>%
  mutate(across(where(is.numeric), ~ replace_na(.x, median(.x, na.rm = TRUE)))) %>%  # NA -> mediana del pueblo
  ungroup() %>%
  mutate(across(c(Magnesium, Proline), as.integer)) %>%  # variables de conteo a entero
  distinct()  # elimina filas duplicadas

# Verificación: sin NAs ni duplicados y mismas dimensiones que el original
stopifnot(sum(is.na(wine)) == 0, !any(duplicated(wine)))
dim(wine)
```

La limpieza se realiza en una sola cadena de pasos:

1. Redondeo a 3 decimales para corregir el valor 9.899999.
2. Eliminación de filas sin pueblo, ya que esa variable no se puede imputar.
3. Conversión del pueblo a *factor* (variable categórica).
4. Imputación de NAs con la **mediana de su pueblo**. Se elige la mediana porque, a diferencia de la media, no se ve afectada por valores atípicos.
5. Conversión de `Magnesium` y `Proline` a enteros.
6. Eliminación de filas duplicadas.

Como no hubo NAs ni duplicados, los pasos 2, 4 y 6 no modificaron los datos, pero quedan listos por si cambia el archivo. La verificación final confirma una base limpia de **178 × 14**, que se exporta como `Wine_clean.csv`.

## 2. Análisis Exploratorio de Datos

### 2.1 Medidas de tendencia central y dispersión

```
tabla_descriptiva <- datos_largos %>%
  group_by(Variable) %>%
  summarise(
    N = n(),
    Media = mean(Valor),
    Mediana = median(Valor),
    Desviacion_estandar = sd(Valor),
    Varianza = var(Valor),
    Minimo = min(Valor),
    Primer_cuartil = quantile(Valor, 0.25),
    Tercer_cuartil = quantile(Valor, 0.75),
    Maximo = max(Valor),
    IQR = IQR(Valor),
    Rango = max(Valor) - min(Valor),
    Coeficiente_variacion = 100 * sd(Valor) / mean(Valor),
    .groups = "drop"
  ) %>%
  arrange(Variable)
```

Para cada variable se calculan medidas de **tendencia central** (media y mediana) y de **dispersión**: desviación estándar, varianza, rango y rango intercuartílico (IQR = Q3 − Q1, el ancho del 50 % central de los datos). El **coeficiente de variación** (CV = 100 · $s$ / $\bar{x}$) expresa la dispersión como porcentaje de la media, lo que permite comparar variables con unidades distintas (Tabla 2). Con el mis-

mo código agrupado por pueblo se obtuvo la tabla `tabla_descriptiva_por_pueblo.csv`.

**Tabla 2.** Estadísticas descriptivas ($n$ = 178).

| Variable | Media | Mediana | DE | IQR | CV % |
|---|---|---|---|---|---|
| Alcohol | 13.001 | 13.050 | 0.812 | 1.315 | 6.2 |
| Ash | 2.367 | 2.360 | 0.274 | 0.348 | 11.6 |
| Ash_Alcanity | 19.495 | 19.500 | 3.340 | 4.300 | 17.1 |
| Color_Intensity | 5.058 | 4.690 | 2.318 | 2.980 | 45.8 |
| Flavanoids | 2.029 | 2.135 | 0.999 | 1.670 | 49.2 |
| Hue | 0.957 | 0.965 | 0.229 | 0.338 | 23.9 |
| Magnesium | 99.742 | 98.000 | 14.282 | 19.0 | 14.3 |
| Malic_Acid | 2.336 | 1.865 | 1.117 | 1.480 | 47.8 |
| Nonflav._Phenols | 0.362 | 0.340 | 0.124 | 0.167 | 34.4 |
| OD280 | 2.612 | 2.780 | 0.710 | 1.232 | 27.2 |
| Proanthocyanins | 1.591 | 1.555 | 0.572 | 0.700 | 36.0 |
| Proline | 746.893 | 673.500 | 314.907 | 484.5 | 42.2 |
| Total_Phenols | 2.295 | 2.355 | 0.626 | 1.057 | 27.3 |

El CV más alto corresponde a `Flavanoids` (49.2 %) y el más bajo a `Alcohol` (6.2 %). En `Proline`, `Malic_Acid` y `Color_Intensity` la media es mayor que la mediana.

### 2.2 Detección de valores atípicos

```
# Se usa el criterio de Tukey: un valor es atípico si se encuentra por debajo
# de Q1 - 1.5*IQR o por encima de Q3 + 1.5*IQR.
tabla_outliers <- datos_largos %>%
  group_by(Variable) %>%
  summarise(
    Q1 = quantile(Valor, 0.25),
    Q3 = quantile(Valor, 0.75),
    IQR = IQR(Valor),
    Limite_inferior = Q1 - 1.5 * IQR,
    Limite_superior = Q3 + 1.5 * IQR,
    Cantidad_outliers = sum(
      Valor < Limite_inferior | Valor > Limite_superior
    ),
    Porcentaje_outliers = 100 * Cantidad_outliers / n(),
    .groups = "drop"
  ) %>%
  mutate(across(where(is.numeric), ~ round(.x, 3))) %>%
  arrange(desc(Cantidad_outliers))
```

El **criterio de Tukey** marca como atípico todo valor fuera del intervalo [Q1 − 1.5·IQR, Q3 + 1.5·IQR]. Se detectaron **21** valores atípicos en 7 de las 13 variables (Tabla 3). No se eliminaron porque pueden ser mediciones válidas; solo se quitarían si se comprobara un error de captura o de medición.

### 2.3 Distribución de las variables

```
# Shapiro-Wilk complementa la inspección gráfica. H0: la variable presenta
# una distribución normal. Un p-valor menor a 0.05 sugiere no normalidad.
tabla_distribucion <- datos_largos %>%
  group_by(Variable) %>%
  summarise(
    Asimetria = mean(
      ((Valor - mean(Valor)) / sd(Valor))^3
    ),
    Shapiro_W = unname(shapiro.test(Valor)$statistic),
    Shapiro_p = shapiro.test(Valor)$p.value,
    Conclusion = if_else(
      Shapiro_p < 0.05,
      "No presenta normalidad",
      "Compatible con normalidad"
    ),
    .groups = "drop"
  ) %>%
  mutate(
    Asimetria = round(Asimetria, 3),
    Shapiro_W = round(Shapiro_W, 3),
    Shapiro_p = signif(Shapiro_p, 4)
  )
```

**Tabla 3.** Valores atípicos según el criterio de Tukey.

| Variable | Lím. inf. | Lím. sup. | n | % |
|---|---|---|---|---|
| Ash_Alcanity | 10.750 | 27.950 | 4 | 2.25 |
| Color_Intensity | −1.250 | 10.670 | 4 | 2.25 |
| Magnesium | 59.500 | 135.500 | 4 | 2.25 |
| Ash | 1.689 | 3.079 | 3 | 1.69 |
| Malic_Acid | −0.617 | 5.303 | 3 | 1.69 |
| Proanthocyanins | 0.200 | 3.000 | 2 | 1.12 |
| Hue | 0.276 | 1.626 | 1 | 0.56 |
| Otras 6 variables | | | 0 | 0.00 |

La **asimetría** es el promedio de los valores estandarizados elevados al cubo: vale 0 en una distribución simétrica y es positiva cuando la cola derecha es más larga. La prueba de **Shapiro-Wilk** contrasta $H_0$: *los datos provienen de una distribución normal*; con $p < 0.05$ se rechaza $H_0$. Solo `Ash_Alcanity` ($p = 0.264$) es compatible con normalidad; las otras 12 variables la rechazan (Tabla 4, Figura 2).

**Tabla 4.** Asimetría y prueba de Shapiro-Wilk por variable.

| Variable | Asimetría | W | p |
|---|---|---|---|
| Alcohol | −0.051 | 0.982 | 0.0200 |
| Ash | −0.174 | 0.984 | 0.0387 |
| Ash_Alcanity | 0.209 | 0.990 | **0.2640** |
| Color_Intensity | 0.854 | 0.940 | $9.23 \times 10^{-7}$ |
| Flavanoids | 0.025 | 0.955 | $1.68 \times 10^{-5}$ |
| Hue | 0.021 | 0.981 | 0.0174 |
| Magnesium | 1.080 | 0.938 | $6.35 \times 10^{-7}$ |
| Malic_Acid | 1.020 | 0.889 | $2.95 \times 10^{-10}$ |
| Nonflav._Phenols | 0.443 | 0.963 | $1.05 \times 10^{-4}$ |
| OD280 | −0.302 | 0.945 | $2.32 \times 10^{-6}$ |
| Proanthocyanins | 0.508 | 0.981 | 0.0145 |
| Proline | 0.755 | 0.931 | $1.74 \times 10^{-7}$ |
| Total_Phenols | 0.085 | 0.977 | 0.0044 |

### 2.4 Comparación de dispersión y outliers

```
# Como las variables tienen unidades diferentes, se estandarizan para poder
# compararlas en una misma gráfica de cajas.
datos_estandarizados <- wine %>%
  mutate(across(where(is.numeric), ~ as.numeric(scale(.x)))) %>%
  pivot_longer(
    cols = -Pueblo,
```

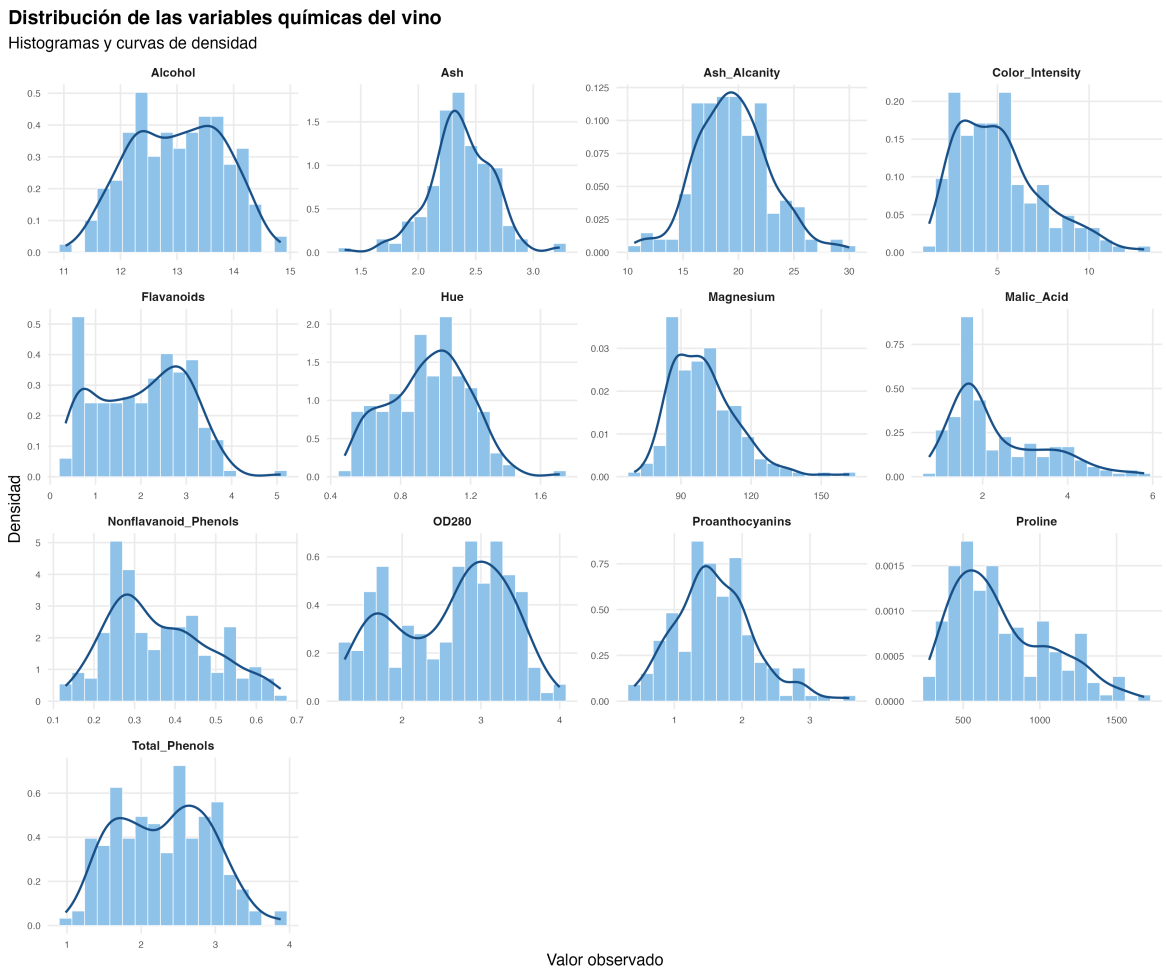



**Figura 2.** Histogramas (barras) y curvas de densidad (línea) de las 13 variables químicas. Cada panel tiene su propia escala en ambos ejes.

```
    names_to = "Variable",
    values_to = "Valor_estandarizado"
  )
```

`scale()` **estandariza** cada variable con $z = (x - \bar{x}) / s$. Así todas quedan con media 0 y desviación estándar 1, y pueden compararse en una misma gráfica de cajas (Figura 3).

### 2.5 Correlaciones entre variables

```
# La correlación permite explorar asociaciones lineales y anticipar posibles
# problemas de multicolinealidad en la regresión del punto 3.
matriz_correlaciones <- wine %>%
  select(-Pueblo) %>%
  cor(use = "complete.obs")
```

El **coeficiente de correlación de Pearson** ($r$) mide la asociación lineal entre dos variables y va de −1 a 1. Las correlaciones más altas fueron `Total_Phenols`–`Flavanoids` ($r$ = 0.865), `Flavanoids`–`OD280` (0.787) y `Total_Phenols`–`OD280` (0.700); las más negativas, `Malic_Acid`–`Hue` (−0.561) y `Flavanoids`–`Nonflavanoid_Phenols` (−0.538). Correlaciones altas entre predictores pueden causar *multicolinealidad* en una regresión (Figura 4).

### 2.6 Variables principales para el punto 3

```
variables_clave <- c(
  "Proline",
  "Alcohol",
  "Flavanoids",
  "Color_Intensity",
  "OD280",
  "Total_Phenols"
)
```

Se seleccionan seis variables para comparar visualmente los tres pueblos antes de aplicar las pruebas formales (Figura 5).

## 3. Inferencia estadística y modelos

```
# Semilla para reproducir particiones, validación cruzada y modelos
```

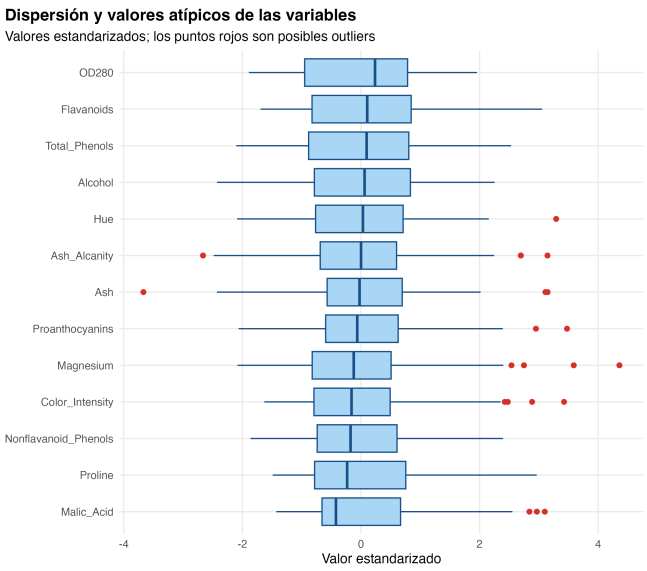



**Figura 3.** Diagramas de caja de las variables estandarizadas. La caja abarca de Q1 a Q3, la línea interior es la mediana y los puntos son los valores atípicos según el criterio de Tukey.

```
480 set.seed(2026)
```

`set.seed()` fija el generador de números aleatorios, de modo que la partición de los datos y la validación cruzada producen siempre los mismos resultados.

### 3.a Descripción de las pruebas y modelos

3.1 **ANOVA de una vía** (y alternativas robustas) para comparar la prolina media entre pueblos.
3.2 **Kruskal-Wallis** por variable para identificar qué compuestos difieren entre pueblos.
3.3 **Regresión lineal múltiple** para predecir la prolina a partir de los demás compuestos.
3.4 **Regresión logística multinomial** para clasificar el pueblo de origen de una muestra.

### 3.1 Prolina por pueblo: ANOVA y supuestos

```
490 # Media y desviación estándar de prolina por pueblo
491 wine %>% group_by(Pueblo) %>%
        ↪ get_summary_stats(Proline, type = "mean_sd")
492
493 # ANOVA clásico; H0: la prolina media es igual en los
        ↪ tres pueblos
494 anova_prolina <- aov(Proline ~ Pueblo, data = wine)
495 summary(anova_prolina)
496
497 # Supuestos: normalidad de residuos (Shapiro-Wilk) y
        ↪ homogeneidad de varianzas (Levene)
498 shapiro.test(residuals(anova_prolina))
499 leveneTest(Proline ~ Pueblo, data = wine)
```

El **ANOVA de una vía** compara las medias de tres o más grupos. Contrasta $H_0$: *las medias de prolina son iguales en los tres pueblos*, mediante el estadístico F, que compara la variación entre grupos con la variación dentro de cada grupo. Supone residuos normales y varianzas iguales entre grupos.

Las medias (± DE) fueron 1116 ± 222 mg/L (Pueblo 1), 520 ± 157 mg/L (Pueblo 2) y 630 ± 115 mg/L (Pueblo 3). Resultados:

- ANOVA: $F(2, 175) = 207.9$, $p < 2 \times 10^{-16}$.
- Shapiro-Wilk sobre los residuos: $W = 0.982$, $p = 0.021$, por lo que **no se cumple** la normalidad (Figura 6).
- Levene: $F(2, 175) = 8.51$, $p = 0.0003$, por lo que **no se cumple** la igualdad de varianzas.

```
511 # Alternativas robustas ante violación de supuestos:
        ↪ ANOVA de Welch y Kruskal-Wallis (+ tamaño de
        ↪ efecto)
512 welch_anova_test(wine, Proline ~ Pueblo)
513 kruskal_test(wine, Proline ~ Pueblo)
514 kruskal_effsize(wine, Proline ~ Pueblo)
515
516 # Comparaciones por pares con Games-Howell (no asume
        ↪ varianzas iguales)
517 gh_prolina <- games_howell_test(wine, Proline ~ Pueblo)
        ↪ %>% mutate(p_lab = scales::pvalue(p.adj, add_p
        ↪ = TRUE))
518 gh_prolina
```

Como no se cumplen los supuestos, se aplican dos alternativas:

- El **ANOVA de Welch**, que no asume varianzas iguales: $F(2, 111.8) = 153.8$, $p = 7.9 \times 10^{-33}$.
- La prueba de **Kruskal-Wallis**, que es no paramétrica y compara rangos en lugar de medias, por lo que no requiere normalidad: $H(2) = 119.1$, $p = 1.4 \times 10^{-26}$.

El **tamaño del efecto** $\eta^2_H = (H - k + 1) / (n - k)$ indica la proporción de la variabilidad explicada por el pueblo: $\eta^2_H = 0.669$, clasificado como *grande* ($\geq 0.14$).

La prueba de **Games-Howell** compara los pueblos por pares sin asumir varianzas iguales (Figura 7):

- Pueblo 2 − Pueblo 1: −596.2 mg/L [IC 95 %: −677.9, −514.5], $p < 0.001$.
- Pueblo 3 − Pueblo 1: −485.8 mg/L [−565.1, −406.5], $p < 0.001$.
- Pueblo 3 − Pueblo 2: 110.4 mg/L [51.1, 169.7], $p < 0.001$.

### 3.2 Kruskal-Wallis por variable

```
534 # Kruskal-Wallis y eta² η(²[H]) para cada variable
        ↪ química, con p-valores ajustados por Bonferroni
535 kw_variables <- wine %>%
536   pivot_longer(-Pueblo, names_to = "Variable",
        ↪ values_to = "Valor") %>%
537   group_by(Variable) %>%
538   summarise(H = kruskal.test(Valor ~ Pueblo)$statistic,
539             p = kruskal.test(Valor ~ Pueblo)$p.value,
540             eta2_H =
        ↪ kruskal_effsize(pick(everything()), Valor ~
        ↪ Pueblo)$effsize) %>%
```

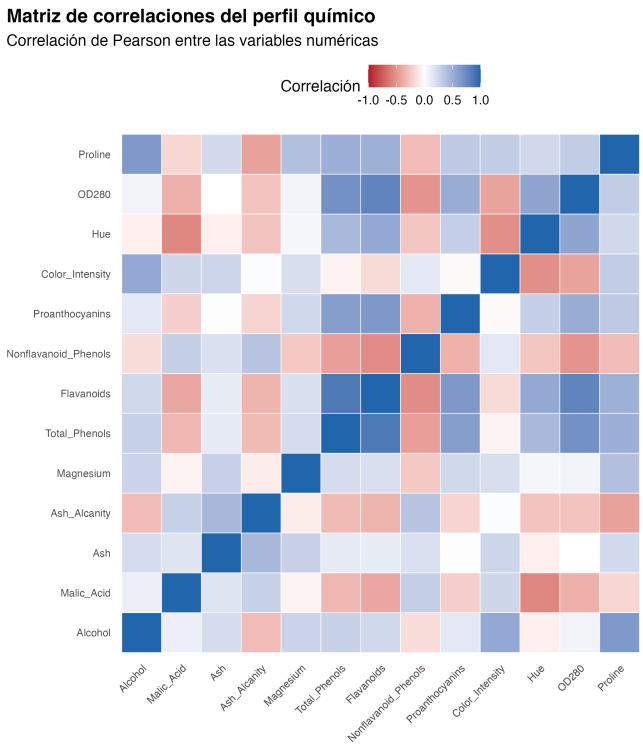



**Figura 4.** Matriz de correlaciones de Pearson entre las 13 variables químicas. Cada celda muestra la correlación de un par de variables, de −1 a 1.

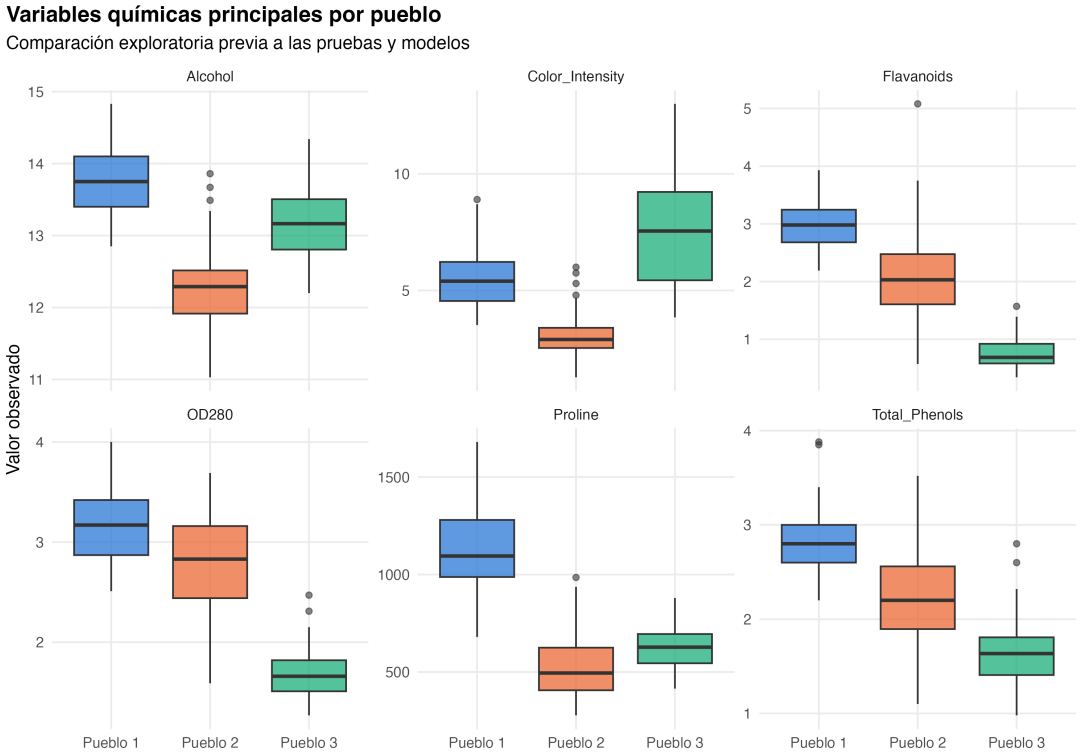



**Figura 5.** Diagramas de caja de seis variables principales en cada pueblo: `Alcohol`, `Color_Intensity`, `Flavanoids`, `OD280`, `Proline` y `Total_Phenols`.

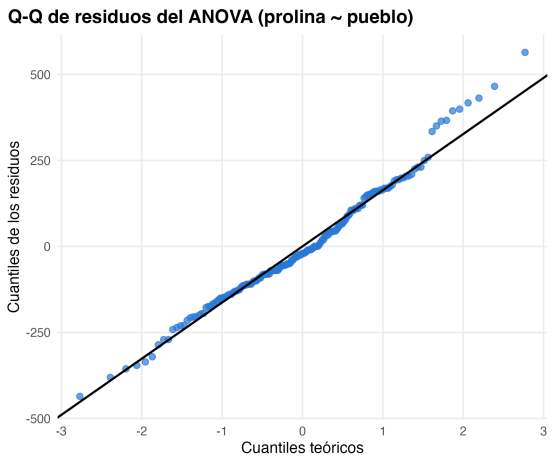



**Figura 6.** Gráfica Q-Q de los residuos del ANOVA. Si los residuos fueran normales, los puntos seguirían la línea recta.

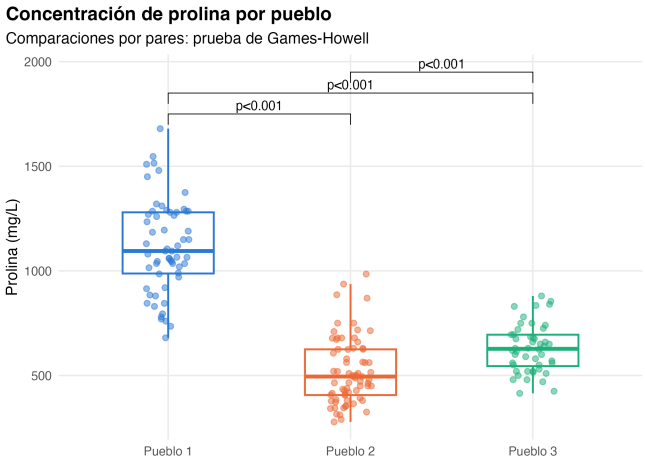



**Figura 7.** Concentración de prolina (mg/L) en cada pueblo. Los puntos son las muestras individuales y los corchetes superiores muestran los *p*-valores ajustados de Games-Howell para cada par de pueblos.

```
    mutate(p_ajustado = p.adjust(p, method =
      ↪ "bonferroni")) %>%
  arrange(desc(eta2_H))
kw_variables
```

Se aplica Kruskal-Wallis a cada una de las 13 variables. Hacer muchas pruebas a la vez aumenta la probabilidad de obtener algún falso positivo. La corrección de **Bonferroni** lo compensa multiplicando cada $p$ por el número de pruebas (13). Las 13 variables obtuvieron $p$ ajustado < 0.001. Solo `Ash` quedó por debajo del umbral de efecto grande, con $\eta^2_H = 0.121$ (Tabla 5, Figura 8).

### 3.3 Regresión lineal múltiple: prolina

```
# Partición estratificada 70/30 por pueblo (la misma se
  ↪ reutiliza en 3.4)
```

**Tabla 5.** Kruskal-Wallis por variable (gl = 2), ordenado por tamaño de efecto.

| Variable | H | $\eta^2_H$ | *p* ajustado |
|---|---|---|---|
| `Flavanoids` | 130.45 | 0.734 | $6.12 \times 10^{-28}$ |
| `Proline` | 119.06 | 0.669 | $1.82 \times 10^{-25}$ |
| `Color_Intensity` | 115.05 | 0.646 | $1.35 \times 10^{-24}$ |
| `Alcohol` | 109.51 | 0.614 | $2.16 \times 10^{-23}$ |
| `OD280` | 107.05 | 0.600 | $7.40 \times 10^{-23}$ |
| `Total_Phenols` | 93.48 | 0.523 | $6.54 \times 10^{-20}$ |
| `Hue` | 92.44 | 0.517 | $1.10 \times 10^{-19}$ |
| `Ash_Alcanity` | 59.99 | 0.331 | $1.22 \times 10^{-12}$ |
| `Proanthocyanins` | 59.47 | 0.328 | $1.58 \times 10^{-12}$ |
| `Malic_Acid` | 50.04 | 0.275 | $1.77 \times 10^{-10}$ |
| `Magnesium` | 40.58 | 0.220 | $2.01 \times 10^{-8}$ |
| `Nonflav._Phenols` | 39.86 | 0.216 | $2.88 \times 10^{-8}$ |
| `Ash` | 23.13 | 0.121 | $1.23 \times 10^{-4}$ |

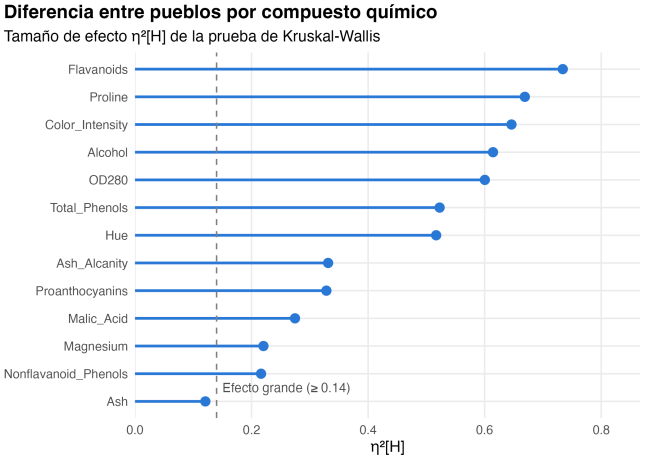



**Figura 8.** Tamaño de efecto $\eta^2_H$ de la prueba de Kruskal-Wallis para cada variable. La línea discontinua marca el umbral de efecto grande (0.14).

```
idx_train <- createDataPartition(wine$Pueblo, p = 0.7,
  ↪ list = FALSE)
train <- wine[idx_train, ]
test  <- wine[-idx_train, ]

# Modelo completo con los 12 compuestos (sin el pueblo)
  ↪ y selección de variables por AIC en ambos
  ↪ sentidos
lm_completo <- lm(Proline ~ . - Pueblo, data = train)
lm_prolina  <- MASS::stepAIC(lm_completo, direction =
  ↪ "both", trace = FALSE)
summary(lm_prolina)
```

Los datos se dividen en **entrenamiento** (70 %, 126 muestras) y **prueba** (30 %, 52 muestras), manteniendo la proporción de cada pueblo. Una **regresión lineal múltiple** modela la prolina como una suma ponderada de los otros 12 compuestos. `stepAIC()` agrega y quita variables mientras el **criterio de información de Akaike** (AIC) disminuya; el AIC equilibra el ajuste del modelo contra su número de parámetros. El modelo final conservó 8 variables (Tabla 6): $R^2 = 0.636$, $R^2$ ajustado = 0.611, $F(8, 117) = 25.52$,

$p < 2.2 \times 10^{-16}$ y error estándar residual = 190.2 mg/L.

**Tabla 6.** Coeficientes del modelo final para `Proline`.

| Término | Estimado | EE | t | *p* |
|---|---|---|---|---|
| (Intercepto) | −1190.78 | 410.38 | −2.90 | 0.0044 |
| `Alcohol` | 81.54 | 31.32 | 2.60 | 0.0104 |
| `Ash` | 248.78 | 90.09 | 2.76 | 0.0067 |
| `Ash_Alcanity` | −23.57 | 7.26 | −3.24 | 0.0015 |
| `Magnesium` | 2.58 | 1.34 | 1.92 | 0.0570 |
| `Flavanoids` | 69.05 | 26.92 | 2.57 | 0.0116 |
| `Nonflav._Phenols` | −275.10 | 185.55 | −1.48 | 0.1409 |
| `Color_Intensity` | 38.50 | 11.36 | 3.39 | 0.0010 |
| `Hue` | 270.86 | 104.85 | 2.58 | 0.0110 |

Cada coeficiente indica cuánto cambia la prolina predicha (mg/L) al aumentar en una unidad esa variable, manteniendo las demás constantes.

```
# Supuestos: multicolinealidad (VIF > 5 preocupante), heterocedasticidad (Breusch-Pagan) y normalidad de residuos
vif(lm_prolina)
ncvTest(lm_prolina)
shapiro.test(residuals(lm_prolina))
```

Se verifican tres supuestos del modelo (Figura 9):

- **Multicolinealidad**: el factor de inflación de la varianza (VIF) indica cuánto se infla la varianza de un coeficiente por su correlación con los demás predictores. El VIF máximo fue 2.65 (`Color_Intensity`), menor que 5.
- **Homocedasticidad** (varianza constante de los residuos): Breusch-Pagan, $\chi^2(1) = 2.95$, $p = 0.086$, por lo que no se rechaza $H_0$.
- **Normalidad de residuos**: Shapiro-Wilk, $W = 0.992$, $p = 0.676$, por lo que no se rechaza $H_0$.

```
# Desempeño en el conjunto de prueba: RMSE, R² y MAE
pred_prolina <- predict(lm_prolina, newdata = test)
postResample(pred = pred_prolina, obs = test$Proline)
```

El modelo se evalúa con las 52 muestras de prueba, que no se usaron para ajustarlo:

- **RMSE** (raíz del error cuadrático medio) = 210.8 mg/L.
- **MAE** (error absoluto medio) = 162.2 mg/L.
- $R^2 = 0.613$.

El RMSE penaliza más los errores grandes que el MAE (Figura 10).

### 3.4 Regresión logística multinomial: pueblo

```
# Validación cruzada 10-fold sobre entrenamiento; estandariza predictores y ajusta la penalización (decay)
ctrl <- trainControl(method = "cv", number = 10)
multi_pueblo <- train(Pueblo ~ ., data = train, method = "multinom",
                      preProcess = c("center", "scale"), trControl = ctrl,
                      tuneGrid = expand.grid(decay = c(0, 0.001, 0.01, 0.1, 0.5, 1)), trace = FALSE)
multi_pueblo
```

La **regresión logística multinomial** estima la probabilidad de que una muestra pertenezca a cada uno de los tres pueblos a partir de las 13 variables químicas. Los predictores se estandarizan. El parámetro `decay` es una **penalización** que reduce el tamaño de los coeficientes para evitar el sobreajuste, y su valor se eligió con **validación cruzada de 10 pliegues**: el entrenamiento se divide en 10 partes y cada una se usa una vez como validación. El valor elegido fue `decay` = 0.001, con exactitud promedio de 1.000 en la validación cruzada.

```
# Razones de momios por cada desviación estándar de aumento (referencia: Pueblo 1)
exp(coef(multi_pueblo$finalModel))
```

Al exponenciar los coeficientes se obtienen **razones de momios** respecto al Pueblo 1. Un valor mayor que 1 indica que, al aumentar la variable en una desviación estándar, aumentan los momios de pertenecer a ese pueblo frente al Pueblo 1. Por ejemplo: 75.04 para `Ash_Alcanity` (Pueblo 2) y 17.55 para `Color_Intensity` (Pueblo 3).

```
# Desempeño en prueba: matriz de confusión, exactitud, kappa y métricas por clase
pred_pueblo <- predict(multi_pueblo, newdata = test)
cm_pueblo <- confusionMatrix(pred_pueblo, test$Pueblo)
cm_pueblo
```

La **matriz de confusión** cruza el pueblo real con el predicho (Figura 11). En prueba se clasificaron correctamente 51 de 52 muestras:

- **Exactitud** = 0.981 [IC 95 %: 0.897, 0.9995], contra una tasa sin información (NIR) de 0.404 ($p < 2.2 \times 10^{-16}$).
- **Kappa de Cohen** = 0.971. El kappa mide el acuerdo entre lo real y lo predicho, descontando el acuerdo esperado por azar.

La Tabla 7 resume las métricas por clase.

**Tabla 7.** Métricas por clase en el conjunto de prueba.

| Métrica | Pueblo 1 | Pueblo 2 | Pueblo 3 |
|---|---|---|---|
| Sensibilidad | 1.000 | 0.952 | 1.000 |
| Especificidad | 1.000 | 1.000 | 0.974 |
| Exactitud balanceada | 1.000 | 0.976 | 0.987 |

```
# Importancia de variables (magnitud de los coeficientes estandarizados, escala 0-100)
imp_pueblo <- varImp(multi_pueblo)$importance %>%
  rownames_to_column("Variable") %>%
  as_tibble() %>%
  rename(Importancia = Overall) %>%
  arrange(desc(Importancia))
imp_pueblo
```

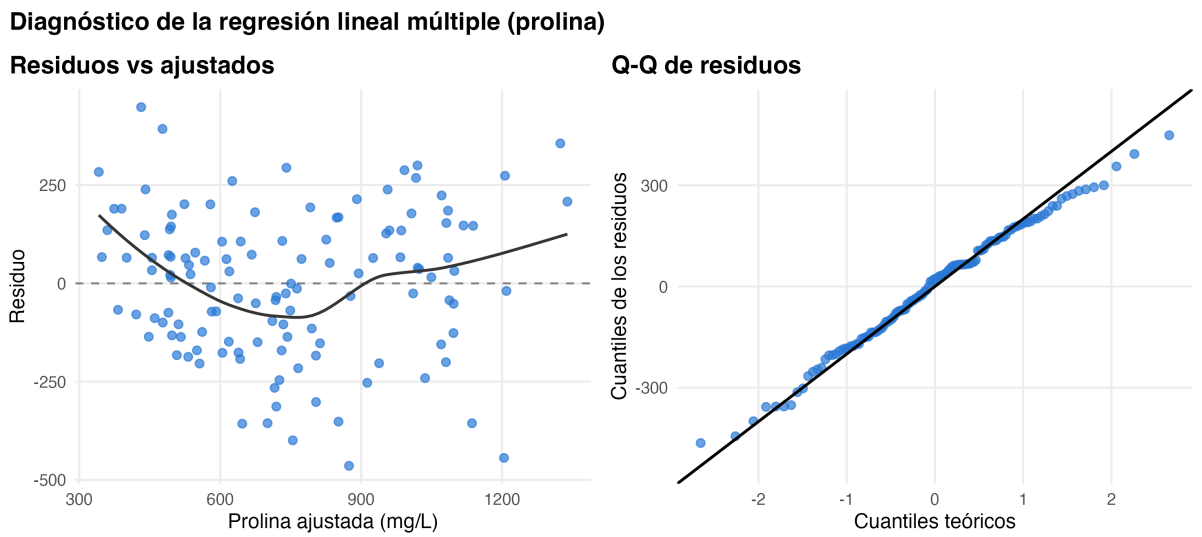



**Figura 9.** Diagnóstico de la regresión lineal múltiple. Izquierda: residuos contra valores ajustados, con una curva de suavizado; se espera una nube sin patrón alrededor de 0. Derecha: gráfica Q-Q de los residuos.

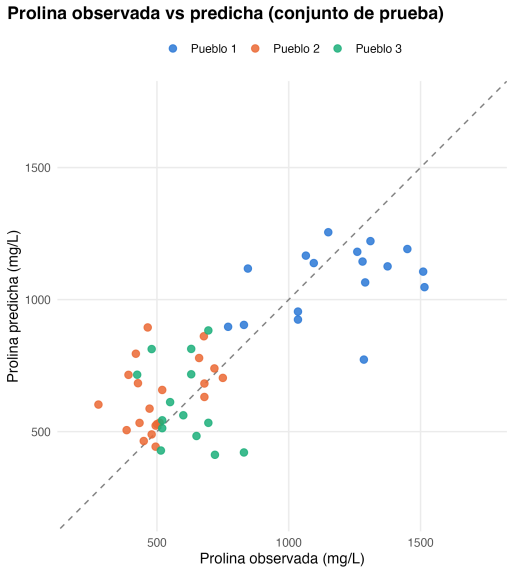



**Figura 10.** Prolina observada contra prolina predicha en el conjunto de prueba (52 muestras), por pueblo. La diagonal discontinua representa una predicción perfecta.

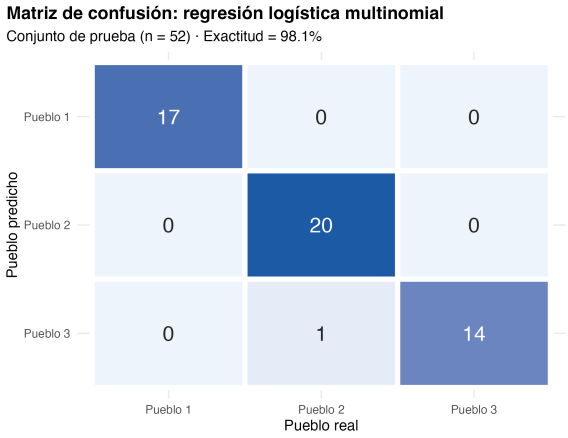



**Figura 11.** Matriz de confusión del modelo multinomial en el conjunto de prueba ($n$ = 52). La diagonal contiene las muestras clasificadas correctamente; la única muestra mal clasificada es del Pueblo 2 y se predijo como Pueblo 3.

La **importancia de variables** reescala la magnitud de los coeficientes estandarizados de 0 a 100. Los valores más altos fueron `Ash_Alcanity` (100), `Proline` (86.3), `Color_Intensity` (84.4) y `Flavanoids` (71.1); los más bajos, `Nonflavanoid_Phenols` (0.4) y `Magnesium` (0) (Figura 12).




**Figura 12.** Importancia relativa (0–100) de cada variable en la regresión logística multinomial, calculada a partir de los coeficientes estandarizados.

## Resumen de resultados

- **Limpieza**: 0 NAs, 0 duplicados y 0 negativos; se corrigió 1 valor con error de formato. La base limpia es de 178 × 14.
- **Exploratorio**: 12 de 13 variables rechazan la normalidad y se detectaron 21 valores atípicos, que se conservaron.
- **3.1**: la prolina difiere entre pueblos (Welch $p = 7.9 \times 10^{-33}$; Kruskal-Wallis $p = 1.4 \times 10^{-26}$; $\eta^2_H = 0.669$). Las tres comparaciones por pares tienen $p < 0.001$.
- **3.2**: las 13 variables difieren entre pueblos ($p$ ajustado < 0.001). El mayor efecto es el de `Flavanoids` ($\eta^2_H = 0.734$) y el menor el de `Ash` (0.121).
- **3.3**: 8 variables explican el 63.6 % de la variación de la prolina ($R^2$ ajustado = 0.611). En prueba, RMSE = 210.8 mg/L y $R^2 = 0.613$, y se cumplen los tres supuestos verificados.
- **3.4**: el modelo multinomial clasifica correctamente 51 de 52 muestras de prueba (exactitud = 0.981, kappa = 0.971).